

FinRAG:金融多模态知识库问答



全球校园人工智能算法精英大赛



Preliminary Round Score

100.00 (Rank 1, tied)

Final Round Score

89.75 (Rank 1)

队伍: Timber

金融知识的困境：海量多模态数据对撞秒级响应需求



· **银行知识库是核心资产，但形式驳杂：**PDF (监管政策)、Excel (审计报告)、图片(业务流程图)、Word (产品说明书) 等构成了一个**海量而复杂**的信息网络。

· **业务需求却要求极致的效率：**客服需要**秒级**回答，风控人员需要即时判断，客户经理需要快速解读。



信息过载：

知识**复杂**、模态形式**多**，难以统一利用。



响应迟缓：

传统检索方式无法满足业务对**速度**的苛刻要求。



决策风险：

错误或**不完整**的信息可能误导关键业务决策。

现有技术路径的局限性：为何传统方法在金融领域失效？

关键词检索

无法理解金融文本的强专业性和抽象概念，导致“搜索结果冗余但核心内容缺失”。



语义理解缺失

直接LLM生成

在长文本输入下易产生幻觉，且缺乏必要的可解释性，不满足金融强监管要求。



不可靠、不可溯源

模型微调

成本高昂、周期长，金融知识库更新频繁，每次更新都需重新训练，维护复杂。




高成本、低灵活性

RAG（检索增强生成）是兼顾轻量、稳定、可解释、易迁移的最佳工程路径，它构建了可控的知识约束，完美契合银行业对合规与风控的要求。

FinRAG 系统架构：端到端的冠军级解决方案

无需微调，即插即用：底层仅依赖BM25与开源LLM Reranker，可直接复用于新知识库，迁移成本极低。

全格式覆盖，场景通吃：通过多模态知识构建，覆盖PDF、Excel、图表等全格式文档，适配客服、风控、内训等多元场景。



极致性能，秒级响应：创新采用多项加速手段，将端到端时延控制在3秒内，满足严苛的业务需求。

第一步：从多模态混乱到结构化知识



Challenge

原始文档**格式多样** (图片, Excel, Word, PPT, PDF), 传统解析工具导致内容**丢失**、结构**错位**、图表信息**遗漏**。



Our Innovation

1. **统一为HTML 格式**: 采用MinerU 将所有文档**统一**转换为结构化**HTML**。利用其级联架构, 精确定位段落、标题、表格、图像等20余类区域。
2. **真正看懂图像**: 构建“**OCR提取+VLM语义分析+结构化描述生成**”流程, 将流程图、图表从“**无法检索的图片**”转为“**可理解的知识**”, 检索利用率从 **<10%** 提升至 **>90%**。



Key Detail

通过“**路径剥离**”的分块策略, 确保分块结果不受文件存储路径影响, 保证了后续检索的**稳定性**和**可复现性**。

原始文档



传统解析提取结果

原超家B8 次多彬 IPDF, Word, 跑所树又蝶破一快换
9 增 稀 ICHTL 民程多照势笼拉, 就艳G, 铭聘宏,
失利扶、即武思罐恩, 超妞耀入够弦E 另临民四器折
招图斑 (Hallucination), 雍图疾、路到甜AL “尧恐
紫、语裙珊” 特3” 句瞳8318R”, 竣我用零从
< 1 0 % 度升筵 > 9 0 % . JIMAGE
500,000 12月 6月
400,000 395,987 430,420
300,000 70 0 70
300,000 S0 80
200,000

MinerU

结构化HTML

Elements Console Sources Network >>

<p>邮寄地址: 中国上海市黄浦区中山南路1号</p>

<p></p>

<p></p>

<h1 id="董事长致辞">董事长致辞</h1>

<p></p>

<p></p>

<h1 id="尊敬的股东朋友">尊敬的股东朋友: </h1>

<p>

"2020年, 比其他年份来得似乎更为特别一些。一场疫情突如其来, 举国战“疫”。面对国内经济环境不确定性增多、风险挑战上升、疫情防控常态化等复杂局面, 我们坚守战略定力, 一如既往地努力着, 奔跑着"

</p>

<p>

"我们创造具有里程

Depository Recei

公司。中国太保近

发挥了公司治理机

底线, 才能全力服

此次发行GDR, 既是

为持续完"

</p>

<p> == \$0

"集团归母营运利润

Rendered size: 376 x 224 px
Rendered aspect ratio: 47 : 28
Intrinsic size: 537 x 320 px
Intrinsic aspect ratio: 537 : 320
File size: 19.5 kB
Current source: data:image/jpeg;base64,/9j/4AAQSkZJRgABAQAAQABAAQ.../AKCKvUyGJLeCOGNdscahVHoBwKfQAUUUUAAFFFBRRRQB/Z/

真正看懂图像

利用率从 **<10%** 提升至 **>90%**

内容丢失、结构错位、图表信息遗漏

第二步：精准召回

核心：内容语义与主题结构双路检索

 Challenge

在百万级文本块中，单一的稀疏检索易导致“召回不全”或“主题漂移”。



路径1:文本块检索(内容语义匹配)

目标：面向全文知识库，进行全局召回。

机制：基于BM25 算法，精准捕获与问题语义最接近的句子或段落。



路径2:路径检索(主题结构定位)


目标：面向文件路径(如“信贷/个贷/利率政策.pdf”), 进行主题召回。

机制：路径天然蕴含主题信息，能补充因词频不足而被忽略的主题强相关文档。



高质量候选集
语义高度契合
+
主题强相关

检索准确度对比



准确度从79.55% 提升至93.73%(+14.2%),
而时间仅从0.05 s 增加到 0.06 s 。

第三步：LLM精排与动态路由，从相关到确信

LLM Reranker精排



Top K 精排结果



Challenge

粗排结果虽相关，但仍混有语义关联露的噪声，直接输入LLM会导致回答偏差。



Mechanism


抛弃传统机器学习依赖人工特征的方式，利用大模型的深层语义理解能力，对“查询-文档”对进行二次排序，将语义契合度最高的文本块置于最前。



Advantage

克服了稀疏检索仅依赖词频匹配的局限性。

动态路由策略



全局检索：

应对跨文档综合分析类问题。



定点穿透：

针对特定文档的深度问答，通过硬过滤条件锁定单一文档，有效解决跨文档噪声干扰问题。



基于文档元数据 (Metadata)，智能选择检索范围。


第四步：生成模型选型与推理框架



第五步：克服“注意力稀释”的双阶段生成策略，打造完美答案


The LLM Challenge:注意力稀释

当LLM 处理由多个文本块拼接而成的长上下文时，其**注意力**会被**分散**，导致最核心的证据无法获得足够关注，**影响**答案的**精准度**。




我们的解决方案：“初次多块总结+二次核心强化”

阶段一 (Summarize)



生成一个**覆盖所有**潜在证据的初步回答，确保信息**全面性**。




阶段二 (Reinforce)



此举强制模型**聚焦**核心证据，挖掘关键细节，确保答案**精准度**。

双阶段策略将最终答案准确度从**93.11%**提升至**96.65%**,实现了**超过3%**的净增长

第六步：从30秒到3秒，为企业级应用设计的全链路性能工程



6倍+ 性能提升

跨阶段并行调度

将“检索-精排-生成”的串行模式重构为**流水线**，
允许不同查询在不同阶段**并行**处理。

端到端延迟从**31秒**降至**5秒**

185倍 性能提升

高效稀疏检索 (BM25s)

采用BM25s, 通过预计算TF值和稀疏矩阵运算，
变“逐文档计算”为“**矩阵级批量计算**”。

检索300条查询耗时从**37秒**降至**0.2秒**

2倍+ 性能提升

高效精排

在关键层设置判定节点，根据相似度得分
动态提前退出，避免无效计算。

在**28层**实现**速度与精度**的最佳**平衡**

系统实际运行展示

金融多模态知识库构建与复杂问答检索算法
智能助手

1. 输入问题。

2. 等待智能助手返回答案 🗨️

输入问题:

中国人寿保险（集团）公司2022年女性员工总数是多少？女性管理者占比是多少？

选择文档来源(可选):

65HTML

开始回答

答案 🗨️

回答:

• 女性员工总数: 10.19万人

• 女性管理者占比: 36.09%

(依据文档0中明确提到的数据: “全系统18.84万名员工中, 女性员工总数达10.19万人, 占比约54%; 全体管理者中, 女性管理者占比达36.09%。”)

简洁的智能助手交互界面。

选择文档来源(可选):

无

无

65HTML

previous

上海浦东发展银行

上海银行

中信银行

中国人寿保险

中国农业银行

支持“全量语料”或“单一文档”的动态检索。

文档列表 📄

文档0

文档1

文档2

回答结果清晰，并展示关联度最高的Top3 文档来源，实现内容可溯源。

延迟信息 ⌚ 🔗

总耗时

12929 ms

后端耗时

12928 ms

网络耗时

1 ms

延迟来源: 后端检索/生成阶段

支持延迟显示，量化系统响应时间，验证高效性能。

最终的验证： 赛场上的绝对优势

赛段	模型配置	成绩	排名
赛段： 初赛	模型配置： Fastest /Origin	成绩： 100.00	排名： Top 1 (并列)
赛段： 复赛	模型配置： Fastest /Origin	成绩： 89.75	排名： Top 1

赛题覆盖987份多格式金融文档 (PPT,PDF,Word,Image,Excel等),考验系统的综合处理能力。

成绩是检验系统设计与工程实现的唯一标准。

科学的评测：基于多智能体协同构建高质量验证集

Challenge:

如何**客观**、**大规模**地评测金融问答系统的准确性？

人工构造数据既耗时又易引入**偏见**。

Evaluation Metric

采用**关键词召回率 (Keyword Recall Rate)**, 放弃关注表面相似度的BLEU/ROUGE, 聚焦于对**事实准确性**的刚性要求。

通过**闭环**、**协同的自动化**流程, 构建了与原始文档强关联的高质量验证集, 确保了评测结果的客观与可信。

Multi-Agent数据生成流水线

出题Agent

模拟真实用户, 从文档中反向生多样化、有深度的问题。

解题与关键词提取Agent

生成标准答案, 并提炼出评估必需的核心关键词 (Key Information Points)。

核验Agent

作为**质量门卫**, 校验“问题-关键词”对的逻辑一致性与事实准确性。



实验数据解析(1):检索与生成质量的量化提升

Experiment 1: 检索策略有效性



准确度**提升14.2%**,而成本几乎不变,
证明了主题召回的巨大价值。

Experiment 2: 生成策略有效性




二次强化有效克服注意力稀释,
准确度**提升超3%**。

实验数据解析(2):全链路性能优化的显著成果

流水线调度


串行 vs 流水线



系统吞吐率提升超**6倍**, 实现了从分钟级到**秒级**的跨越。

高效稀疏检索


传统BM25 vs BM25s



185倍速度提升, 且准确度几乎无损

上下文压缩

无压缩 vs 上下文压缩



推理效率提升**34%**, 准确度几乎不变。

结论：FinRAG——金融AI的高效、可信、可复用工程范式

高精度

从结构化解析、双路检索到双阶段生成，全链路保障**答案质量**。

高效率

流水线、BM25s动态早退等机制，实现企业级**秒级响应**。

强可解释性

RAG 天然具备内容**溯源**能力，完美契合金融**监管**要求



让你的创见，
成为万物互联
的最强Agent!

FinRAG不仅是一个比赛两阶段的**冠军**方案，更是金融机构知识智能化升级的**高性价比**路径。

它提供了一套**可复用的工程范式**，无需复杂微调，即可为银行业构建更加**可信**、**高效**的智能问答系统。